

Mastering Word Embeddings

De Conceitos a Aplicações Práticas

Os **Word Embeddings** transformam palavras em vetores densos, permitindo que máquinas compreendam relações semânticas complexas. Diferente do One-hot, os embeddings capturam o contexto e o significado.

ESPAÇO 300D
(Complexo)



ESPAÇO 2D
(t-SNE)

Visualização de agrupamentos semânticos

One-hot vs. Vetores de Características

Atributo	One-hot Encoding	Word Embeddings
Estrutura	Esparsa (muitos zeros)	Densa (valores reais)
Relação	Nula (independente)	Semântica (relacionada)
Dimensão	Tamanho do Vocabulário	Fixa (ex: 300D)
Generalização	Baixa	Alta

A representação vetorial permite que o modelo entenda que "Maçã" e "Laranja" são frutas similares.

Representação por Atributos:

	Homem	Mulher	Rei	Rainha
Gênero	-1.0	1.0	-0.95	0.97
Realeza	0.01	0.02	0.93	0.95
Idade	0.03	0.02	0.70	0.69

Cada palavra torna-se um ponto em um espaço N-dimensional, onde a proximidade indica similaridade de significado.

Transfer Learning: Maximizando Dados Limitados

1



Aprendizado em Larga Escala

Treinar Word Embeddings em um **corpus** **massivo** de texto (1B a 100B de palavras) ou baixar modelos pré-treinados online.

2



Transferência de Conhecimento

Transferir os vetores para uma **tarefa** **específica** com conjunto de dados menor (ex: 100k palavras).

3



Fine-tuning (Opcional)

Ajustar os embeddings com os novos dados para que o modelo se especialize no **domínio específico**.

Por que usar Transfer Learning?

Permite que modelos de NLP alcancem alta precisão mesmo quando o usuário possui poucos dados rotulados, "herdando" a compreensão semântica básica de modelos treinados em toda a internet.

Analogias Matemáticas e Relações Semânticas

A estrutura interna dos **Word Embeddings** permite que relações semânticas complexas sejam resolvidas através de aritmética vetorial simples. O modelo aprende a codificar conceitos como gênero, realeza e tempo em direções específicas no espaço vetorial.

- ✓ **Regularidade:** A diferença entre vetores de palavras relacionadas é frequentemente constante.
- ✓ **Espaço Relacional:** O vetor que liga "Homem" a "Mulher" é quase paralelo ao que liga "Rei" a "Rainha".
- ✓ **Generalização:** Isso permite ao modelo inferir relações para palavras que nunca viu juntas.

A Equação da Analogia:

$$e_{\text{man}} - e_{\text{woman}} \approx e_{\text{king}} - e_{\text{queen}}$$

Onde e_w representa o vetor da palavra w .

Exemplos de Relações:

- Paris - França + Itália = Roma
- Bigger - Big + Small = Smaller
- Yen - Japão + Rússia = Rublo

Similaridade de Cosseno e Algoritmo de Analogia

Para encontrar a palavra que melhor completa uma analogia, buscamos maximizar a similaridade entre os vetores:

$$\text{sim}(u, v) = \frac{u^T v}{\|u\|_2 \|v\|_2}$$

Onde $u^T v$ é o produto escalar e $\|u\|_2$ representa a norma euclidiana (comprimento) do vetor.

Objetivo da Analogia:

$$\text{argmax}_w \text{sim}(e_w, e_{\text{king}} - e_{\text{man}} + e_{\text{woman}})$$



Foco na Orientação

Mede o cosseno do ângulo entre vetores. Se o ângulo é 0°, a similaridade é 1 (máxima).



Independente de Magnitude

Diferente da distância euclidiana, não é afetada pela frequência da palavra no texto.



Intuição Semântica

Palavras com significados parecidos "apontam" para a mesma direção no espaço multidimensional.

Matriz de Características: A Anatomia do Significado

Decomposição Semântica de Palavras:

Atributo	Homem	Mulher	Rei	Rainha	Maçã	Laranja
Gênero	-1.0	1.0	-0.95	0.97	0.00	0.01
Realeza	0.01	0.02	0.93	0.95	-0.01	0.00
Idade	0.03	0.02	0.70	0.69	0.03	-0.02
Alimento	0.09	0.01	0.02	0.01	0.95	0.97

Dimensões de Significado

Cada linha representa uma "feature" ou atributo latente que o modelo aprendeu a identificar no corpus de texto.

Agrupamento Lógico

Observe como **Maçã** e **Laranja** compartilham valores quase idênticos para o atributo 'Alimento', permitindo que o modelo generalize propriedades entre elas.

Densidade de Informação

Em um modelo real, existem centenas de dimensões (ex: 300D), capturando nuances que vão além da compreensão humana direta.

Paralelo Técnico: NLP vs. Visão Computacional

A

Word Embeddings

Em NLP, convertemos uma **palavra** em um vetor denso (ex: 300D). A rede neural aprende que palavras com significados próximos devem ter vetores próximos.

Conceito: Mapeamento semântico de linguagem.

[0.12, -0.54, 0.89, ..., 0.21]



Face Encodings

Em sistemas como o **DeepFace**, convertemos uma **imagem de rosto** em um vetor (ex: 128D). A rede aprende que a mesma pessoa deve gerar vetores similares.

Conceito: Mapeamento de identidade visual.

[0.45, 0.11, -0.32, ..., 0.76]

A Essência é a Mesma: Ambas as tecnologias utilizam redes profundas para criar uma representação numérica compacta e significativa de dados complexos, permitindo cálculos de similaridade em um espaço vetorial.

Aplicação Prática: Named Entity Recognition (NER)

O uso de **Word Embeddings** revoluciona o NER ao permitir que o modelo generalize para palavras que nunca viu durante o treinamento, baseando-se no contexto semântico.

Sally Johnson **PERSON** is an orange farmer.

Robert Lin **PERSON** is an apple farmer.

Mesmo que o nome "Robert Lin" seja novo para o modelo, a estrutura vetorial de "apple" e "farmer" fornece pistas contextuais idênticas às de "orange" e "farmer", facilitando a classificação correta.

Por que funciona?

- ✓ **Generalização:** O modelo aprende padrões de contexto em vez de memorizar nomes específicos.
- ✓ **Robustez:** Funciona bem com vocabulários limitados (ex: 100k palavras) se os embeddings forem pré-treinados.
- ✓ **Eficiência:** Reduz drasticamente a necessidade de dados rotulados para novas tarefas de extração.

"A densidade de informação nos vetores é o que permite ao modelo 'intuir' o significado de termos desconhecidos."