

Word Embeddings: Guia Técnico de Revisão

Da Representação Vetorial à Ética na IA

Embeddings: Capturando Semântica em Vetores Densos

Embeddings são representações densas e de baixa dimensão de palavras ou entidades, onde a semântica é capturada pela proximidade vetorial. Diferente do one-hot encoding, que cria vetores esparsos e de alta dimensão sem capturar relações semânticas, os embeddings permitem que palavras com significados semelhantes estejam próximas no espaço vetorial.

Essa representação densa é crucial para modelos de Processamento de Linguagem Natural (PLN) modernos, pois permite que eles compreendam o contexto e as relações entre as palavras de forma mais eficiente e significativa. Por exemplo, palavras como "rei" e "rainha" teriam vetores próximos, e a diferença vetorial entre elas poderia ser similar à diferença entre "homem" e "mulher".

Por que precisamos de Embeddings?

- One-hot encoding resulta em vetores esparsos e de alta dimensão.
- Não captura relações semânticas entre palavras.
- Embeddings oferecem representações densas e contextuais.
- Permitem que modelos de PLN compreendam o significado e o contexto das palavras.

A Matriz de Embedding (E): A Base Matemática

A matriz de embedding, geralmente denotada por **E**, é o coração dos sistemas de word embeddings. Ela é uma matriz de $V \times D$, onde V é o tamanho do vocabulário (número de palavras únicas) e D é a dimensão do embedding (o tamanho do vetor que representa cada palavra).

Cada linha da matriz **E** corresponde a um vetor de embedding para uma palavra específica no vocabulário. Assim, se temos uma palavra com índice i no vocabulário, seu vetor de embedding é a i -ésima linha da matriz **E**.

Essa matriz é aprendida durante o treinamento do modelo de embedding, ajustando os valores dos vetores para que palavras com significados semelhantes tenham vetores próximos no espaço vetorial.

Operação de Lookup:

Para obter o vetor de embedding de uma palavra, realizamos uma operação de "lookup" na matriz **E**. Se a palavra é representada por um vetor one-hot x (onde apenas a posição correspondente à palavra é 1 e o restante é 0), o vetor de embedding e é obtido pela multiplicação da matriz **E** pelo vetor one-hot x :

$$e = E \cdot x$$

Isso efetivamente seleciona a linha da matriz **E** que corresponde à palavra desejada. Essa operação é fundamental para converter palavras discretas em representações contínuas que podem ser usadas por redes neurais e outros modelos de aprendizado de máquina.

Analogias e a Geometria do Espaço Vetorial

Aritmética de Vetores

Uma das propriedades mais fascinantes dos embeddings é a capacidade de resolver analogias através de operações matemáticas simples. Isso ocorre porque as relações semânticas são codificadas como direções e distâncias consistentes no espaço vetorial.

O exemplo clássico demonstra que a diferença entre os vetores de "Homem" e "Mulher" é aproximadamente a mesma que entre "Rei" e "Rainha":

$$e_{\text{rei}} - e_{\text{homem}} + e_{\text{mulher}} \approx e_{\text{rainha}}$$

Medindo a Similaridade

Para determinar o quão próximas duas palavras estão, utilizamos métricas geométricas. A mais comum é a **Similaridade de Cosseno**, que mede o ângulo entre dois vetores em vez de sua magnitude linear.

Isso permite que o modelo identifique sinônimos e termos relacionados, independentemente da frequência com que aparecem no corpus de treinamento, focando puramente na orientação semântica do conceito.



Skip-grams e GloVe: Algoritmos de Aprendizado

Embora ambos gerem vetores densos, as abordagens matemáticas para o aprendizado dos embeddings diferem significativamente entre modelos preditivos e baseados em contagem.

Característica	Word2Vec (Skip-gram)	GloVe (Global Vectors)
Abordagem	Preditiva : Tenta prever o contexto (palavras vizinhas) dada uma palavra central.	Baseada em Contagem : Foca na matriz de co-ocorrência global de palavras.
Escopo	Local: Analisa janelas específicas de texto por vez.	Global: Captura estatísticas de todo o corpus de uma só vez.
Vantagem	Melhor em capturar nuances sintáticas e analogias complexas.	Mais eficiente no uso de estatísticas globais e estável em grandes corpora.
Mecânica	Usa Softmax Hierárquico ou Negative Sampling para otimização.	Minimiza a diferença entre o produto escalar dos vetores e o log da probabilidade de co-ocorrência.

O DESAFIO DO VIÉS: QUANDO A IA HERDA PRECONCEITOS

Os Word Embeddings são treinados em vastos corpora de texto (como Wikipedia ou notícias). Consequentemente, eles acabam absorvendo e amplificando estereótipos culturais e preconceitos implícitos presentes na linguagem humana.

Esse fenômeno não é apenas uma falha técnica, mas um reflexo de desigualdades históricas que, se não tratadas, podem automatizar a discriminação em sistemas de busca, recrutamento e tradução.

Exemplos de Analogias Enviesadas:



"Homem está para Programador assim como Mulher está para Dona de Casa"



"Pai está para Médico assim como Mãe está para Enfermeira"

Impacto Social e Ético

A presença de viés em modelos de linguagem pode levar a:

- **Exclusão Digital:** Resultados de busca que reforçam estereótipos de gênero ou raça.
- **Injustiça Algorítmica:** Sistemas de triagem de currículos que penalizam candidatos com base em nomes associados a certas etnias.
- **Propagação de Estereótipos:** Traduções automáticas que assumem gêneros para profissões de forma tendenciosa.

PASSO 1: IDENTIFICANDO A DIREÇÃO DO VIÉS

O Eixo do Viés

Para mitigar o viés, primeiro precisamos isolar a direção matemática que o representa no espaço vetorial. No caso de gênero, identificamos um conjunto de pares de palavras que definem o conceito (ex: rei/rainha, homem/mulher).

A direção do viés é encontrada calculando a diferença entre esses vetores e identificando a componente comum que explica a maior parte da variação entre eles.

Metodologia Técnica

Utiliza-se a técnica de **Análise de Componentes Principais (PCA)** sobre as diferenças dos pares definicionais:

$$\mu = \text{average}(\mathbf{e}_{\text{he}} - \mathbf{e}_{\text{she}}, \mathbf{e}_{\text{male}} - \mathbf{e}_{\text{female}}, \dots)$$

Onde $\mathbf{g}$ (direção do viés) é a primeira componente principal resultante.

Esta direção $\mathbf{g}$ captura o "eixo de gênero" que queremos neutralizar em palavras neutras.

Passo 2: Neutralização de Termos Não-Definicionais

A **Neutralização** visa remover a componente de viés de palavras que não possuem gênero intrínseco, mas que acabaram "enviesadas" devido ao treinamento em dados históricos.

Projetamos o valor da palavra no espaço ortogonal ao eixo de viés identificado no Passo 1, removendo a componente indesejada e preservando as demais características semânticas.

Ao final deste processo, a similaridade de cosseno entre a palavra neutralizada e os extremos do eixo de viés (ex: "ele" e "ela") deve ser idêntica.

Mecânica Técnica:

$$\mathbf{e_final} = \mathbf{e} - \mathbf{e_bias}$$

Onde $\mathbf{e_bias}$ é a projeção do vetor original no eixo de viés.

Exemplos de termos neutralizados:

- Recepcionista
- Babá
- Inteligente
- Cientista

PASSO 3: EQUALIZAÇÃO DE PARES DEFINICIONAIS

O Objetivo da Equalização

Garantir que palavras com gênero intrínseco (ex: avô/avó) fiquem exatamente à mesma distância de palavras que foram neutralizadas (ex: bebê, doutor).

Sem este passo, "bebê" poderia estar matematicamente mais próximo de "avó" do que de "avô" devido a vieses residuais nos dados, perpetuando associações automáticas indesejadas.



Avô

DISTÂNCIA
IGUAL



Bebê

DISTÂNCIA
IGUAL



Avó

IA RESPONSÁVEL EXIGE VIGILÂNCIA CONSTANTE

Os **Word Embeddings** são a base fundamental de quase todo o NLP moderno, desde tradutores automáticos até os Grandes Modelos de Linguagem (LLMs) atuais.

Embora o **Debiasing** seja uma ferramenta técnica poderosa para mitigar preconceitos, ele não substitui a necessidade crítica de uma curadoria de dados ética e consciente.

A construção de sistemas de IA justos exige um compromisso contínuo com a transparência e a auditoria das representações vetoriais que alimentam nossas tecnologias.

"A tecnologia é um reflexo de nossos dados; cabe a nós garantir que esse reflexo seja justo."

Próximos Passos



Transformers e Mecanismos de Atenção



Large Language Models (LLMs)



Ética e Governança de Dados em IA